

Agence Nissa Bank

MARIANO ALBUQUERQUE, Melissa


Contents

verificando se o endereço é um QPV	1
limpeza e preparação de dados	2
explorando a relação entre os dados	4
segmentação de clientes	5
sugestões de prontos	17
Arguments pour un bon système de gestion de données commerciales	20

```
library(tidyverse) # manipulação do dataframe, renomeação de colunas e seleção de variáveis.
library(cluster)   # suporte a métricas e cálculos complementares de agrupamento (clustering).
library(factoextra) # gerar os gráficos de validação de clusters (teste do cotovelo e silhueta).
library(ggplot2)   # adicionar e customizar títulos e eixos dos gráficos.
library(dendextend) # converter e colorir as ramificações do dendrograma hierárquico.
```

verificando se o endereço é um QPV

uma pesquisa feita no site <https://sig.ville.gouv.fr/> confirma que o endereço está sim em um QPV, como mostra a imagem abaixo.



necessidades dos clientes dessa localidade :

- **produtos que não sejam caros** : les gens ont besoin de trucs simples. Par exemple, une carte bancaire de base et un compte sans frais compliqués (ou gratuits).

- **microcréditos** : les petits commerçants du quartier ont besoin des micro-crédits pour rester ouvert.
- **poupança** : pour mettre de l'argent de côté, ils veulent des choses faciles comme le Livret A.
- **ajuda e conselhos** : c'est important de parler avec eux et de donner des conseils de gestion simples. Pour éviter les gros problèmes d'argent et les dettes.

limpeza e preparação de dados

```
dados <- read.csv("agence_nissa_bank.csv", stringsAsFactors = TRUE)
```



```
str(dados)
```

```
## 'data.frame':    5012 obs. of  9 variables:
## $ ID.Client      : Factor w/ 5012 levels "CL100001","CL100002",...: 1 2 3 4 5 6 7 8 9 10 ...
## $ Nom            : Factor w/ 400 levels "Adam","Albert",...: 149 304 276 360 56 345 393 193 124 105
## $ Prénom         : Factor w/ 215 levels "Adélaïde","Adèle",...: 122 76 6 60 207 109 214 94 100 2 ..
## $ Âge            : int   19 46 37 21 23 23 61 55 51 36 ...
## $ Situation      : Factor w/ 13 levels "Agent d'entretien",...: 8 9 5 6 5 6 3 6 7 4 ...
## $ Revenu.mensuel.: num   923 2722 1480 1152 1621 ...
## $ Produits.détenus: Factor w/ 5 levels "Compte courant",...: 3 5 1 5 4 3 4 4 3 1 ...
## $ Crédit.en.cours: Factor w/ 5 levels "Aucun crédit",...: 1 5 5 2 4 5 5 5 1 3 ...
## $ Épargne..      : num   671 1538 2279 1086 1162 ...
```

```
summary(dados)
```

```
##      ID.Client      Nom      Prénom      Âge
## CL100001: 1 Rossi : 25 Suzanne : 53 Min. :18.00
## CL100002: 1 Sanchez : 23 Margot : 45 1st Qu.:28.00
## CL100003: 1 Dupuis : 22 Michelle: 45 Median :40.00
## CL100004: 1 Legendre: 22 Nathalie: 45 Mean :41.36
## CL100005: 1 Vallée : 22 Aurélie : 37 3rd Qu.:53.00
## CL100006: 1 Da Costa: 21 Victoire: 35 Max. :85.00
## (Other) :5006 (Other) :4877 (Other) :4752
##      Situation      Revenu.mensuel..
## Employé :1196 Min. : 0.17
## Employé précaire: 822 1st Qu.:1043.55
## Étudiant : 622 Median :1477.33
## Sans emploi : 526 Mean :1439.67
## Retraité : 357 3rd Qu.:1860.75
## Artisan : 346 Max. :2989.13
## (Other) :1143
##      Produits.détenus      Crédit.en.cours
## Compte courant :1235 Aucun crédit :1304
## Compte courant + Assurance habitation : 664 Crédit consommation: 933
## Compte courant + Carte bancaire :1261 Découvert autorisé :1005
## Compte courant + Carte bancaire + Livret A: 606 Microcrédit :1071
## Compte courant + Livret A :1246 Prêt automobile : 699
##
##      Épargne..
## Min. : 0.24
## 1st Qu.: 325.44
## Median : 777.55
## Mean :1172.95
## 3rd Qu.:1686.01
## Max. :6999.30
##
```

```
names(dados)
```

```
## [1] "ID.Client"      "Nom"      "Prénom"      "Âge"
## [5] "Situation"      "Revenu.mensuel.." "Produits.détenus" "Crédit.en.cours"
## [9] "Épargne.."
```

```
dados_modif <- rename(dados,
  id_client = "ID.Client",
  nom = "Nom",
  prenom = "Prénom",
  age = "Âge",
  situation = "Situation",
  revenu_mensuel = "Revenu.mensuel..",
  produits_detenus = "Produits.détenus",
  credit_en_cours = "Crédit.en.cours",
  epargne = "Épargne..")
```

```
# removendo pelas posições (indica para dropar da coluna 1 até a coluna 3)
dados_modif <- select(dados_modif, -c(1:3))
```

```
# cria um novo dataframe apenas com as colunas numéricas
dados_numericos <- select(dados_modif, where(is.numeric))
```

```
# cria um novo dataframe apenas com os fatores/categóricas
dados_categoricos <- select(dados_modif, where(is.factor))
```

```
preparar_dados <- function(dataset) {
  matriz_dummies <- model.matrix(~ . - 1, data = dataset)
  df_dummies <- as.data.frame(matriz_dummies)

  normalizar_min_max <- function(x) {
    if (max(x) - min(x) == 0) return(x)
    return((x - min(x)) / (max(x) - min(x)))
  }

  dados_normalizados <- as.data.frame(lapply(df_dummies, normalizar_min_max))
  return(dados_normalizados)
}
```

```
pronto_tudo <- preparar_dados(dados_modif)
```

explorando a relação entre os dados

aqui começa os testes para entender melhor a relação que as variáveis têm entre si, para saber quais variáveis devem ser escolhidas como features do nosso modelo de K-means.

```
# Calcula a correlação de Pearson entre todas as colunas numéricas
matriz_cor <- cor(dados_numericos, use = "complete.obs")
```

```
# Exibe a matriz de números no console
print(matriz_cor)
```

```
##                age revenu_mensuel  epargne
## age                1.0000000    0.2606446  0.1401195
## revenu_mensuel    0.2606446    1.0000000  0.6753114
## epargne           0.1401195    0.6753114  1.0000000
```

embora a renda e a poupança apresentem uma correlação linear positiva moderada/forte ($\rho = 0.675$), optou-se por manter ambas na segmentação.

no algoritmo de agrupamento K-means, elas representam dimensões distintas do comportamento do cliente (capacidade de ganho versus acumulação de patrimônio).

a eventual redundância geométrica é controlada pela aplicação da normalização Min-Max, preservando a variância essencial de cada perfil sem os problemas de inversão de matriz típicos de uma regressão linear.

```
# teste 1: profissão vs produtos
qui_1 <- chisq.test(table(dados_modif$situation, dados_modif$produits_detenus))
```

```
# teste 2: profissão vs crédito
qui_2 <- chisq.test(table(dados_modif$situation, dados_modif$credit_en_cours))

# teste 3: produtos vs crédito
qui_3 <- chisq.test(table(dados_modif$produits_detenus, dados_modif$credit_en_cours))

# exibe os p-values para o seu relatório
cat("=== RESULTADOS DOS TESTES QUI-QUADRADO (P-VALUES) ===\n")
```

```
## === RESULTADOS DOS TESTES QUI-QUADRADO (P-VALUES) ===
```

```
cat("Situação vs Produtos: ", qui_1$p.value, "\n")
```

```
## Situação vs Produtos: 1.197069e-113
```

```
cat("Situação vs Crédito: ", qui_2$p.value, "\n")
```

```
## Situação vs Crédito: 8.230077e-50
```

```
cat("Produtos vs Crédito: ", qui_3$p.value, "\n")
```

```
## Produtos vs Crédito: 7.634666e-14
```


os testes provam que as três variáveis são fortemente dependentes entre si.

o comportamento dos clientes da Nissa Bank não é aleatório. A situação profissional de um cliente está diretamente amarrada ao tipo de produto que ele consome e ao tipo de crédito que ele pega. Da mesma forma, o produto que ele tem dita o tipo de crédito que ele utiliza.


esses resultados dão a validação científica perfeita para a escolha das suas features. Se um p-value desses tivesse dado maior que 0,05, significaria que a variável era “ruído” (irrelevante) e criar dummies para ela só serviria para deixar o algoritmo *K*-means confuso e lento. Como todas mostraram associações gigantescas, você acabou de provar que deixar as três variáveis na base e transformá-las em dummies é o caminho correto, pois cada uma delas carrega um padrão de comportamento único e crucial para desenhar os 4 perfis de clientes da agência.

segmentação de clientes

```
# gráfico do cotovelo
fviz_nbclust(pronto_tudo, kmeans, method = "wss", linecolor = "#FF10F0") +
  labs(title = "Teste do Cotovelo (Método WSS)", x = "Número de Clusters K", y = "Soma dos Quadrados Den
```



```
# gráfico da silhueta média  
fviz_nbclust(pronto_tudo, kmeans, method = "silhouette", linecolor = "#FF10F0") +  
  labs(title = "Teste do Coeficiente de Silhueta", x = "Número de Clusters K", y = "Silhueta Média")
```



quando não sabemos a quantidade ideal de grupos para dividir nossos clientes, fazemos uma análise de clustering exploratória primeiro, e nesse caso a análise é feita com o *agrupamento hierárquico*, que é uma técnica não supervisionada de machine learning, ou seja, ela não serve para extrapolar a amostra, mas serve muito bem para o que preciso agora que é ter uma ideia de como os clusters se dividem naturalmente.

ele cria um gráfico chamado “dendograma” que mostra como os clusters se dividem.

```
# 1. calcula a matriz de distância geométrica
matriz_distancia <- dist(pronto_tudo, method = "euclidean")


# 2. executa o agrupamento hierárquico (Método de Ward)
modelo_hierarquico <- hclust(matriz_distancia, method = "ward.D2")

# 3. converte o resultado para um objeto dendrograma
dend <- as.dendrogram(modelo_hierarquico)

# 4. colore as ramificações dos 4 grupos com as cores neon (processamento otimizado)
dend <- color_branches(dend, k = 4, col = c("#39FF14", "#FF10F0", "#FF5F1F", "#00FFFF"))

# 5. plota o dendrograma modificado removendo os rótulos individuais das folhas (leaflab = "none")
plot(dend, leaflab = "none", main = "Dendrograma de Clientes - Análise Exploratória",
     xlab = "Clientes", ylab = "Distância")
```

Dendrograma de Clientes – Análise Exploratória



e quando nós já fizemos uma análise prévia e já decidimos quantos grupos vamos trabalhar, passamos para outra técnica de machine learning não supervisionado, o *K-means*.

só que, nesse caso, precisamos escolher entre o que os dados estão nos indicando e o que é prático no mundo real.

```
# EXECUÇÃO DOS DOIS MODELOS EM PARALELO (4 E 8 CLUSTERS)
# garante que os resultados sejam sempre os mesmos ao rodar
set.seed(123)
```

```
# modelo A: a preferência do negócio (4 Clusters)
modelo_k4 <- kmeans(pronto_tudo, centers = 4, nstart = 25)
dados_modif$cluster_4 <- as.factor(modelo_k4$cluster)
```

```
# modelo B: o ideal matemático (8 Clusters)
modelo_k8 <- kmeans(pronto_tudo, centers = 8, nstart = 25)
dados_modif$cluster_8 <- as.factor(modelo_k8$cluster)
```

```
# COMPARAÇÃO DO TAMANHO DOS GRUPOS
cat("=== DISTRIBUIÇÃO DOS CLIENTES EM 4 CLUSTERS ===\n")
```

```
## === DISTRIBUIÇÃO DOS CLIENTES EM 4 CLUSTERS ===
```

```
print(table(dados_modif$cluster_4))
```

```
##
```



```
##      1      2      3      4
## 1196 1391 1402 1023
```

```
cat("\n")
```

```
cat("=== DISTRIBUIÇÃO DOS CLIENTES EM 8 CLUSTERS ===\n")
```

```
## === DISTRIBUIÇÃO DOS CLIENTES EM 8 CLUSTERS ===
```

```
print(table(dados_modif$cluster_8))
```

```
##
##      1      2      3      4      5      6      7      8
## 722 622 616 526 468 872 489 697
```

```
# PERFILAMENTO DOS 4 CLUSTERS (K = 4)
```

```
cat("\n#####\n")
```

```
##
## #####
```

```
cat("                CARACTERÍSTICAS DOS 4 CLUSTERS                \n")
```

```
##                CARACTERÍSTICAS DOS 4 CLUSTERS
```

```
cat("#####\n\n")
```

```
## #####
```

```
# 1. Numéricas (Mediana) para 4 clusters
```

```
perfil_num_k4 <- aggregate(cbind(age, revenu_mensuel, epargne) ~ cluster_4, data = dados_modif, FUN = m
perfil_num_k4[, 2:4] <- round(perfil_num_k4[, 2:4], 2)
print("=== NUMÉRICAS (Mediana) ===")
```

```
## [1] "=== NUMÉRICAS (Mediana) ==="
```

```
print(perfil_num_k4)
```

```
##      cluster_4 age revenu_mensuel epargne
## 1           1  41          1884.72 1680.95
## 2           2  33           975.68  382.61
## 3           3  44          1595.93  972.40
## 4           4  38          1152.70  523.88
```

```
# 2. Categóricas (Proporção) para 4 clusters
```

```
cat("\n=== CATEGÓRICAS: Situação Profissional (%) ===\n")
```

```
##
## === CATEGÓRICAS: Situação Profissional (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_4, dados_modif$situation), margin = 1), 4) * 100)
```

```
##
##      Agent d'entretien Aide à domicile Artisan Caissier Employé Employé précaire
##  1           0.00           0.00      0.00      0.00 100.00           0.00
##  2           1.44           2.95      5.97      2.37  0.00          14.74
##  3           3.42           6.85     12.77      6.70  0.00          27.10
##  4           1.96           4.30      8.21      2.74  0.00          23.17
##
##      Entrepreneur local Étudiant Fonctionnaire Livreur Retraité Sans emploi
##  1           0.00      0.00           0.00      0.00      0.00      0.00
##  2           2.59     30.98           4.39      1.80      5.97     25.09
##  3           8.27      0.00          15.05      3.28     12.34      0.00
##  4           3.13     18.67           6.06      2.54      9.87     17.30
##
##      Serveur
##  1      0.00
##  2      1.73
##  3      4.21
##  4      2.05
```

```
cat("\n=== CATEGÓRICAS: Produtos Detidos (%) ===\n")
```

```
##
## === CATEGÓRICAS: Produtos Detidos (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_4, dados_modif$produits_detenus), margin = 1), 4) * 100)
```

```
##
##      Compte courant Compte courant + Assurance habitation
##  1           20.32           22.24
##  2           27.46           0.00
##  3           43.51           28.39
##  4           0.00           0.00
##
##      Compte courant + Carte bancaire Compte courant + Carte bancaire + Livret A
##  1           21.07           17.73
##  2           72.54           0.00
##  3           0.00           28.10
##  4           0.00           0.00
##
##      Compte courant + Livret A
##  1           18.65
##  2           0.00
##  3           0.00
##  4          100.00
```

```
cat("\n=== CATEGÓRICAS: Crédito em Curso (%) ===\n")
```

```
##
## === CATEGÓRICAS: Crédito em Curso (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_4, dados_modif$credit_en_cours), margin = 1), 4) * 100)
```

```
##
##      Aucun crédit Crédit consommation Découvert autorisé Microcrédit
## 1      20.48          17.39          19.40          21.91
## 2      31.42          20.13          21.50          20.27
## 3      22.61          18.26          19.19          21.26
## 4      29.81          18.48          20.04          22.39
##
##      Prêt automobile
## 1      20.82
## 2       6.69
## 3      18.69
## 4       9.29
```

```
# PERFILAMENTO DOS 8 CLUSTERS (K = 8)
```

```
cat("\n\n#####\n")
```

```
##
##
## #####
```

```
cat("          CARACTERÍSTICAS DOS 8 CLUSTERS          \n")
```

```
##          CARACTERÍSTICAS DOS 8 CLUSTERS
```

```
cat("#####\n\n")
```

```
## #####
```

```
# 1. Numéricas (Mediana) para 8 clusters
```

```
perfil_num_k8 <- aggregate(cbind(age, revenu_mensuel, epargne) ~ cluster_8, data = dados_modif, FUN = m
perfil_num_k8[, 2:4] <- round(perfil_num_k8[, 2:4], 2)
print("=== NUMÉRICAS (Mediana) ===")
```

```
## [1] "=== NUMÉRICAS (Mediana) ==="
```

```
print(perfil_num_k8)
```

```
## cluster_8 age revenu_mensuel epargne
## 1      1  41      1866.90 1658.14
## 2      2  22       583.44  384.96
## 3      3  44      1714.72 1216.12
## 4      4  40       571.76  181.16
## 5      5  45      1780.71 1439.23
## 6      6  47      1711.84 1290.70
## 7      7  42      1578.65  971.88
## 8      8  41      1280.82  575.00
```

```
# 2. Categóricas (Proporção) para 8 clusters
```

```
cat("\n=== CATEGÓRICAS: Situação Profissional (%) ===\n")
```

```
##
```

```
## === CATEGÓRICAS: Situação Profissional (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_8, dados_modif$situation), margin = 1), 4) * 100)
```

```
##
```

```
##      Agent d'entretien Aide à domicile Artisan Caissier Employé Employé précaire
```

```
## 1      0.00      0.00      0.00      0.00 100.00      0.00
```

```
## 2      0.00      0.00      0.00      0.00  0.00      0.00
```

```
## 3      3.25      6.66     13.47      5.36  34.09      0.00
```

```
## 4      0.00      0.00      0.00      0.00  0.00      0.00
```

```
## 5      2.14      5.34     11.11      3.63  44.44      0.00
```

```
## 6      5.28      9.40     17.20      8.49  0.00      0.00
```

```
## 7      2.45      6.75     12.47      6.34  11.45     25.56
```

```
## 8      0.00      0.00      0.00      0.00  0.00     100.00
```

```
##
```

```
##      Entrepreneur local Étudiant Fonctionnaire Livreur Retraité Sans emploi
```

```
## 1      0.00      0.00      0.00      0.00      0.00      0.00
```

```
## 2      0.00    100.00      0.00      0.00      0.00      0.00
```

```
## 3      5.84      0.00      9.90      4.06     13.47      0.00
```

```
## 4      0.00      0.00      0.00      0.00      0.00    100.00
```

```
## 5      5.56      0.00     11.32      3.63     10.26      0.00
```

```
## 6     10.21      0.00     19.15      4.70     20.07      0.00
```

```
## 7      6.75      0.00     10.84      2.86     10.43      0.00
```

```
## 8      0.00      0.00      0.00      0.00      0.00      0.00
```

```
##
```

```
##      Serveur
```

```
## 1      0.00
```

```
## 2      0.00
```

```
## 3      3.90
```

```
## 4      0.00
```

```
## 5      2.56
```

```
## 6      5.50
```

```
## 7      4.09
```

```
## 8      0.00
```

```
cat("\n=== CATEGÓRICAS: Produtos Detidos (%) ===\n")
```

```
##
```

```
## === CATEGÓRICAS: Produtos Detidos (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_8, dados_modif$produits_detenus), margin = 1), 4) * 100)
```

```
##
```

```
##      Compte courant Compte courant + Assurance habitation
```

```
## 1      26.87      31.16
```

```
## 2      34.08      0.00
```

```
## 3      0.00      0.00
```

```
##      4      32.32      0.00
##      5      24.79      21.58
##      6      26.95      23.17
##      7      26.99      17.59
##      8      25.25      7.17
##
##      Compte courant + Carte bancaire  Compte courant + Carte bancaire + Livret A
##      1              0.00              24.10
##      2             35.21              0.00
##      3            100.00              0.00
##      4             34.03              0.00
##      5              8.97             19.66
##      6              0.00             21.22
##      7              0.00             16.36
##      8             29.41             10.76
##
##      Compte courant + Livret A
##      1             17.87
##      2             30.71
##      3              0.00
##      4             33.65
##      5             25.00
##      6             28.67
##      7             39.06
##      8             27.40
```

```
cat("\n=== CATEGÓRICAS: Crédito em Curso (%) ===\n")
```

```
##
## === CATEGÓRICAS: Crédito em Curso (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_8, dados_modif$credit_en_cours), margin = 1), 4) * 100)
```

```
##
##      Aucun crédit  Crédit consommation  Découvert autorisé  Microcrédit
##      1      27.29      0.00      25.48      20.36
##      2      38.91      19.13      21.22      20.74
##      3      23.21      12.34      20.45      23.38
##      4      34.79      21.10      21.86      22.24
##      5       0.00     100.00       0.00       0.00
##      6      36.70       0.00      32.00       0.00
##      7       0.00       0.00       0.00     100.00
##      8      31.42      22.81      24.25       6.46
##
##      Prêt automobile
##      1      26.87
##      2       0.00
##      3      20.62
##      4       0.00
##      5       0.00
##      6      31.31
##      7       0.00
##      8      15.06
```

o escolhido foi o modelo de 4 grupos, porque é impraticável uma empresa ter mais de 4 personas para se comunicar. o trabalho de marketing tem que ser muito bem definido e coeso, o que não seria possível com 8 grupos, até porque quem fala com todo mundo, não fala com ninguém ;)

```
# RESUMO INDIVIDUALIZADO POR PERSONA (K = 4)

for (i in 1:4) {
  cat("\n===== \n")
  cat(paste("                PERFIL DA PERSONA", i, "\n"))
  cat("===== \n")

  # Isola os dados apenas do cluster iterado no momento
  dados_cluster <- subset(dados_modif, cluster_4 == i)

  # Calcula o tamanho do grupo em relação ao total da agência
  tamanho <- nrow(dados_cluster)
  proporcao_base <- round((tamanho / nrow(dados_modif)) * 100, 2)
  cat(paste("Volume de Clientes: ", tamanho, " (", proporcao_base, "% da base total)\n\n", sep = ""))

  # Indicadores Numéricos (Mediana)
  cat("--- Indicadores Numéricos ---\n")
  cat("• Idade:           ", median(dados_cluster$age), "anos\n")
  cat("• Renda Mensal:     €", round(median(dados_cluster$revenu_mensuel), 2), "\n")
  cat("• Poupança:         €", round(median(dados_cluster$epargne), 2), "\n\n")

  # Indicadores Categóricos (Exibe apenas as categorias presentes no grupo > 0%)
  cat("--- Comportamento Categórico Interno ---\n")

  cat("\n> Situação Profissional (%):\n")
  freq_sit <- round(prop.table(table(dados_cluster$situation)) * 100, 2)
  print(freq_sit[freq_sit > 0])

  cat("\n> Produtos Detidos (%):\n")
  freq_prod <- round(prop.table(table(dados_cluster$produits_detenus)) * 100, 2)
  print(freq_prod[freq_prod > 0])

  cat("\n> Crédito em Curso (%):\n")
  freq_cred <- round(prop.table(table(dados_cluster$credit_en_cours)) * 100, 2)
  print(freq_cred[freq_cred > 0])
}
```

```
##
## =====
##                PERFIL DA PERSONA 1
## =====
## Volume de Clientes: 1196 (23.86% da base total)
##
## --- Indicadores Numéricos ---
## • Idade:           41 anos
## • Renda Mensal:     € 1884.72
## • Poupança:         € 1680.95
##
## --- Comportamento Categórico Interno ---
##
```

```

## > Situação Profissional (%):
## Employé
##      100
##
## > Produtos Detidos (%):
##
##                Compte courant
##                20.32
##      Compte courant + Assurance habitation
##                22.24
##                Compte courant + Carte bancaire
##                21.07
##      Compte courant + Carte bancaire + Livret A
##                17.73
##                Compte courant + Livret A
##                18.65
##
## > Crédito em Curso (%):
##
##      Aucun crédit  Crédit consommation  Découvert autorisé  Microcrédit
##                20.48                17.39                19.40                21.91
##      Prêt automobile
##                20.82
##
## =====
##                PERFIL DA PERSONA 2
## =====
## Volume de Clientes: 1391 (27.75% da base total)
##
## --- Indicadores Numéricos ---
## • Idade:                33 anos
## • Renda Mensal:        € 975.68
## • Poupança:            € 382.61
##
## --- Comportamento Categórico Interno ---
##
## > Situação Profissional (%):
##
##      Agent d'entretien  Aide à domicile  Artisan  Caissier
##                1.44                2.95                5.97                2.37
##      Employé précaire  Entrepreneur local  Étudiant  Fonctionnaire
##                14.74                2.59                30.98                4.39
##                Livreur  Retraité  Sans emploi  Serveur
##                1.80                5.97                25.09                1.73
##
## > Produtos Detidos (%):
##
##                Compte courant  Compte courant + Carte bancaire
##                27.46                72.54
##
## > Crédito em Curso (%):
##
##      Aucun crédit  Crédit consommation  Découvert autorisé  Microcrédit
##                31.42                20.13                21.50                20.27

```

```

##      Prêt automobile
##              6.69
##
## =====
##                      PERFIL DA PERSONA 3
## =====
## Volume de Clientes: 1402 (27.97% da base total)
##
## --- Indicadores Numéricos ---
## • Idade:              44 anos
## • Renda Mensal:      € 1595.93
## • Poupança:          € 972.4
##
## --- Comportamento Categórico Interno ---
##
## > Situação Profissional (%):
##
## Agent d'entretien   Aide à domicile      Artisan      Caissier
##              3.42              6.85              12.77              6.70
## Employé précaire Entrepreneur local      Fonctionnaire      Livreur
##              27.10              8.27              15.05              3.28
##              Retraité              Serveur
##              12.34              4.21
##
## > Produtos Detidos (%):
##
##                      Compte courant
##                      43.51
##      Compte courant + Assurance habitation
##                      28.39
## Compte courant + Carte bancaire + Livret A
##                      28.10
##
## > Crédito em Curso (%):
##
##      Aucun crédit Crédit consommation Découvert autorisé      Microcrédit
##              22.61              18.26              19.19              21.26
##      Prêt automobile
##              18.69
##
## =====
##                      PERFIL DA PERSONA 4
## =====
## Volume de Clientes: 1023 (20.41% da base total)
##
## --- Indicadores Numéricos ---
## • Idade:              38 anos
## • Renda Mensal:      € 1152.7
## • Poupança:          € 523.88
##
## --- Comportamento Categórico Interno ---
##
## > Situação Profissional (%):
##

```



```
## Agent d'entretien Aide à domicile Artisan Caissier
## 1.96 4.30 8.21 2.74
## Employé précaire Entrepreneur local Étudiant Fonctionnaire
## 23.17 3.13 18.67 6.06
## Livreur Retraité Sans emploi Serveur
## 2.54 9.87 17.30 2.05
##
## > Produtos Detidos (%):
## Compte courant + Livret A
## 100
##
## > Crédito em Curso (%):
##
## Aucun crédit Crédit consommation Découvert autorisé Microcrédit
## 29.81 18.48 20.04 22.39
## Prêt automobile
## 9.29
```

sugestões de prontos

```
# =====
# ANÁLISE DE AFINIDADE (LIFT) PARA CROSS-SELLING E UP-SELLING
# =====
```

```
cat("\n#####\n")
```

```
##
## #####
```

```
cat(" CÁLCULO DE LIFT (AFINIDADE) POR CLUSTER \n")
```

```
## CÁLCULO DE LIFT (AFINIDADE) POR CLUSTER
```

```
cat("#####\n")
```

```
## #####
```

```
# 1. Calcula a proporção de cada produto e crédito na base TOTAL da agência
prop_base_produtos <- prop.table(table(dados_modif$produits_detenus))
prop_base_credito <- prop.table(table(dados_modif$credit_en_cours))

# 2. Loop para calcular e imprimir o Lift para cada um dos 4 clusters
for (i in 1:4) {
  cat("\n===== \n")
  cat(paste(" LIFT - CLUSTER", i, "\n"))
  cat("===== \n")

  # Filtra os dados apenas para o cluster atual
  dados_cluster <- subset(dados_modif, cluster_4 == i)
```

```

# Calcula a proporção de produtos e créditos dentro do cluster
prop_cluster_produtos <- prop.table(table(dados_cluster$produits_detenus))
prop_cluster_credito <- prop.table(table(dados_cluster$credit_en_cours))

# Calcula o Lift (Proporção no Cluster dividida pela Proporção na Base Geral)
lift_produtos <- prop_cluster_produtos / prop_base_produtos
lift_credito <- prop_cluster_credito / prop_base_credito

# Exibe os resultados separados entre o que deve ser ofertado e o que deve ser evitado
cat("\n> PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):\n")
produtos_fortes <- round(lift_produtos[lift_produtos > 1], 2)
if(length(produtos_fortes) > 0) print(sort(produtos_fortes, decreasing = TRUE)) else cat("Nenhum produto forte.\n")

cat("\n> PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):\n")
produtos_fracos <- round(lift_produtos[lift_produtos < 1], 2)
if(length(produtos_fracos) > 0) print(sort(produtos_fracos)) else cat("Nenhum produto fraco.\n")

cat("\n-----\n")

cat("> CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):\n")
creditos_fortes <- round(lift_credito[lift_credito > 1], 2)
if(length(creditos_fortes) > 0) print(sort(creditos_fortes, decreasing = TRUE)) else cat("Nenhum crédito forte.\n")

cat("\n> CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):\n")
creditos_fracos <- round(lift_credito[lift_credito < 1], 2)
if(length(creditos_fracos) > 0) print(sort(creditos_fracos)) else cat("Nenhum crédito fraco.\n")
}

```

```

##
## =====
##                      LIFT - CLUSTER 1
## =====
##
## > PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
##      Compte courant + Assurance habitation
##                                1.68
## Compte courant + Carte bancaire + Livret A
##                                1.47
##
## > PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##      Compte courant + Livret A          Compte courant
##                                0.75          0.82
## Compte courant + Carte bancaire
##                                0.84
##
## -----
## > CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
## Prêt automobile      Microcrédit
##          1.49          1.03
##

```

```

## > CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##      Aucun crédit Crédit consommation Découvert autorisé
##      0.79          0.93          0.97
##
## =====
##                      LIFT - CLUSTER 2
## =====
##
## > PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
## Compte courant + Carte bancaire          Compte courant
##                      2.88                      1.11
##
## > PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##      Compte courant + Assurance habitation
##                      0
## Compte courant + Carte bancaire + Livret A
##                      0
##      Compte courant + Livret A
##                      0
##
## -----
## > CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
##      Aucun crédit Crédit consommation Découvert autorisé
##      1.21          1.08          1.07
##
## > CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
## Prêt automobile      Microcrédit
##      0.48          0.95
##
## =====
##                      LIFT - CLUSTER 3
## =====
##
## > PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
## Compte courant + Carte bancaire + Livret A
##                      2.32
##      Compte courant + Assurance habitation
##                      2.14
##                      Compte courant
##                      1.77
##
## > PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
## Compte courant + Carte bancaire          Compte courant + Livret A
##                      0                      0
##
## -----
## > CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):

```

```

## Prêt automobile
##          1.34
##
## > CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##          Aucun crédit Découvert autorisé Crédit consommation      Microcrédit
##          0.87          0.96          0.98          0.99
##
## =====
##                      LIFT - CLUSTER 4
## =====
##
## > PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
## Compte courant + Livret A
##          4.02
##
## > PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##                      Compte courant
##                      0
##      Compte courant + Assurance habitation
##                      0
##      Compte courant + Carte bancaire
##                      0
## Compte courant + Carte bancaire + Livret A
##                      0
##
## -----
## > CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
## Aucun crédit      Microcrédit
##          1.15          1.05
##
## > CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##      Prêt automobile Crédit consommation Découvert autorisé
##          0.67          0.99          1.00

```

Argumentos para un bon système de gestion de données commerciales

Donnez 3 arguments solides.

1. Segmentação Precisa e Aumento de Vendas (Cross-selling) Um sistema de gestão de dados estruturado e limpo é o pré-requisito fundamental para aplicar algoritmos de inteligência artificial, como a clusterização K-means que você acabou de executar. Ele permite cruzar histórico de transações com dados demográficos para calcular a afinidade de produtos (Lift). Sem esse sistema, o banco faria ofertas genéricas; com ele, a agência consegue direcionar a campanha de microcrédito exatamente para a pessoa com maior probabilidade de conversão.
2. Eficiência Operacional e Mitigação de Riscos de Crédito A integração de dados comerciais elimina silos de informação dentro da agência. Quando o gerente acessa o perfil de um cliente, ele vê o quadro

completo em tempo real (idade, renda, poupança e créditos ativos). Isso não apenas acelera o tempo de atendimento presencial, mas fornece uma base matemática segura para a análise de risco, evitando a concessão de limite de cheque especial ou novos empréstimos para perfis com alta probabilidade de inadimplência.

3. Conformidade Regulatória e Segurança da Informação (RGPD) Operando na França, a gestão rigorosa de dados de clientes é uma exigência legal imposta pelo Regulamento Geral sobre a Proteção de Dados (RGPD). Um sistema comercial sólido garante que informações financeiras sensíveis sejam armazenadas com criptografia adequada e controle de acesso. Além disso, permite gerenciar o consentimento dos clientes e executar rapidamente solicitações de direito ao esquecimento ou portabilidade de dados, blindando a agência contra vazamentos e multas severas.