

agence nissa bank - estratégia de segmentação de clientes

MARIANO ALBUQUERQUE, Melissa


Contents

verificando se o endereço é um QPV	1
limpeza e preparação de dados	2
explorando a relação entre os dados	5
segmentação de clientes	7
por que precisamos de um bom sistema de gestão de dados comerciais?	23
KPIs para acompanhar na agência do Nissa Bank	24
4. Definição de KPI para pilotar a agência	24

```
library(tidyverse) # manipulação do dataframe, renomeação de colunas e seleção de variáveis.
library(cluster)   # suporte a métricas e cálculos complementares de agrupamento (clustering).
library(factoextra) # gerar os gráficos de validação de clusters (teste do cotovelo e silhueta).
library(ggplot2)    # adicionar e customizar títulos e eixos dos gráficos.
library(dendextend) # converter e colorir as ramificações do dendrograma hierárquico.
```


verificando se o endereço é um QPV

uma pesquisa feita no site <https://sig.ville.gouv.fr/> confirma que o endereço está sim em um QPV, como mostra a imagem abaixo.



ideias de necessidades que os clientes dessa localidade podem ter :

- **produtos que não sejam caros** : geralmente, esses clientes preferem produtos bancários que sejam simples, e que não sejam caros, ou, preferencialmente, gratuitos.
- **microcréditos** : alguns clientes podem precisar de linhas de créditos para tirar seus planos do papel ou até mesmo alguns autônomos podem precisar de empréstimos para se manter no mercado.
- **ajuda e conselhos** : é muito importante ensinar os clientes a como lidar com dinheiro e como minimizar os efeitos dos juros ou outras situações financeiras do gênero. Pour éviter les gros problèmes d'argent et les dettes.
- **poupança** : geralmente, esses clientes estão tentando apenas não se endividar e sobrevivendo com o pouco de dinheiro que tem, por isso eles não conhecem produtos sofisticados de investimentos, então a opção mais segura para guardar uma quantia para emergências seria a poupança.



(Série Atlanta, FX)

limpeza e preparação de dados

```
dados <- read.csv("agence_nissa_bank.csv", stringsAsFactors = TRUE)
```



```
str(dados)
```

```
## 'data.frame':    5012 obs. of  9 variables:
## $ ID.Client      : Factor w/ 5012 levels "CL100001","CL100002",...: 1 2 3 4 5 6 7 8 9 10 ...
## $ Nom            : Factor w/ 400 levels "Adam","Albert",...: 149 304 276 360 56 345 393 193 124 105
## $ Prénom         : Factor w/ 215 levels "Adélaïde","Adèle",...: 122 76 6 60 207 109 214 94 100 2 ..
## $ Âge            : int  19 46 37 21 23 23 61 55 51 36 ...
## $ Situation      : Factor w/ 13 levels "Agent d'entretien",...: 8 9 5 6 5 6 3 6 7 4 ...
## $ Revenu.mensuel.: num  923 2722 1480 1152 1621 ...
## $ Produits.détenus: Factor w/ 5 levels "Compte courant",...: 3 5 1 5 4 3 4 4 3 1 ...
## $ Crédit.en.cours : Factor w/ 5 levels "Aucun crédit",...: 1 5 5 2 4 5 5 5 1 3 ...
## $ Épargne..      : num  671 1538 2279 1086 1162 ...
```

```
summary(dados)
```

```
##      ID.Client      Nom      Prénom      Âge
## CL100001: 1 Rossi   : 25 Suzanne : 53 Min.   :18.00
## CL100002: 1 Sanchez : 23 Margot : 45 1st Qu.:28.00
## CL100003: 1 Dupuis  : 22 Michelle: 45 Median :40.00
## CL100004: 1 Legendre: 22 Nathalie: 45 Mean   :41.36
## CL100005: 1 Vallée  : 22 Aurélie : 37 3rd Qu.:53.00
## CL100006: 1 Da Costa: 21 Victoire: 35 Max.   :85.00
```

```
## (Other) :5006 (Other) :4877 (Other) :4752
## Situation Revenu.mensuel..
## Employé :1196 Min. : 0.17
## Employé précaire: 822 1st Qu.:1043.55
## Étudiant : 622 Median :1477.33
## Sans emploi : 526 Mean :1439.67
## Retraité : 357 3rd Qu.:1860.75
## Artisan : 346 Max. :2989.13
## (Other) :1143
## Produits.détenus Crédit.en.cours
## Compte courant :1235 Aucun crédit :1304
## Compte courant + Assurance habitation : 664 Crédit consommation: 933
## Compte courant + Carte bancaire :1261 Découvert autorisé :1005
## Compte courant + Carte bancaire + Livret A: 606 Microcrédit :1071
## Compte courant + Livret A :1246 Prêt automobile : 699
##
## Épargne..
## Min. : 0.24
## 1st Qu.: 325.44
## Median : 777.55
## Mean :1172.95
## 3rd Qu.:1686.01
## Max. :6999.30
##
```

```
names(dados)
```

```
## [1] "ID.Client" "Nom" "Prénom" "Âge"
## [5] "Situation" "Revenu.mensuel.." "Produits.détenus" "Crédit.en.cours"
## [9] "Épargne.."
```

```
dados_modif <- rename(dados,
  id_client = "ID.Client",
  nom = "Nom",
  prenom = "Prénom",
  age = "Âge",
  situation = "Situation",
  revenu_mensuel = "Revenu.mensuel..",
  produits_detenus = "Produits.détenus",
  credit_en_cours = "Crédit.en.cours",
  epargne = "Épargne..")
```

```
# removendo pelas posições (indica para dropar da coluna 1 até a coluna 3)
dados_modif <- select(dados_modif, -c(1:3))
```

```
# cria um novo dataframe apenas com as colunas numéricas
dados_numericos <- select(dados_modif, where(is.numeric))
```

```
# cria um novo dataframe apenas com os fatores/categóricas
dados_categoricos <- select(dados_modif, where(is.factor))
```

```
preparar_dados <- function(dataset) {
  matriz_dummies <- model.matrix(~ . - 1, data = dataset)
  df_dummies <- as.data.frame(matriz_dummies)

  normalizar_min_max <- function(x) {
    if (max(x) - min(x) == 0) return(x)
    return((x - min(x)) / (max(x) - min(x)))
  }

  dados_normalizados <- as.data.frame(lapply(df_dummies, normalizar_min_max))
  return(dados_normalizados)
}
```

```
pronto_tudo <- preparar_dados(dados_modif)
```

explorando a relação entre os dados

aqui começa os testes para entender melhor a relação que as variáveis têm entre si, para saber quais variáveis devem ser escolhidas como features do nosso modelo de K-means.

```
# calcula a correlação de Pearson entre todas as variáveis numéricas
matriz_cor <- cor(dados_numericos, use = "complete.obs")

# exibe a matriz de números no console
print(matriz_cor)
```


```
##
##          age revenu_mensuel  epargne
## age      1.0000000      0.2606446 0.1401195
## revenu_mensuel 0.2606446      1.0000000 0.6753114
## epargne      0.1401195      0.6753114 1.0000000
```

```
# 1. Instale o pacote caso ainda não o tenha no seu ambiente
# install.packages("corrplot")

# 2. Carregue o pacote
library(corrplot)

# 3. Crie a paleta de cores gradiente
# O número (200) indica a quantidade de tons gerados entre as cores para suavizar a transição
paleta_cores <- colorRampPalette(c("#FF10F0", "white", "#39FF14"))(200)

# 4. Plote a matriz de correlação
corrplot(matriz_cor,
  method = "color",
  col = paleta_cores,
  addCoef.col = "black",
  tl.col = "black",
  tl.srt = 45)
```

embora a renda e a poupança apresentem uma correlação linear positiva moderada/forte ($\rho = 0.675$), optou-se por manter ambas na segmentação.

no algoritmo de agrupamento K-means, elas representam dimensões distintas do comportamento do cliente (capacidade de ganho versus acumulação de patrimônio).

a eventual redundância geométrica é controlada pela aplicação da normalização Min-Max, preservando a variância essencial de cada perfil sem os problemas de inversão de matriz típicos de uma regressão linear.

```
# teste 1: profissão vs produtos
qui_1 <- chisq.test(table(dados_modif$situation, dados_modif$produits_detenus))

# teste 2: profissão vs crédito
qui_2 <- chisq.test(table(dados_modif$situation, dados_modif$credit_en_cours))

# teste 3: produtos vs crédito
qui_3 <- chisq.test(table(dados_modif$produits_detenus, dados_modif$credit_en_cours))

# exibe os p-values para o seu relatório
cat("=== RESULTADOS DOS TESTES QUI-QUADRADO (P-VALUES) ===\n")
```

```
## === RESULTADOS DOS TESTES QUI-QUADRADO (P-VALUES) ===
```

```
cat("Situação vs Produtos: ", qui_1$p.value, "\n")
```

```
## Situação vs Produtos: 1.197069e-113
```

```
cat("Situação vs Crédito: ", qui_2$p.value, "\n")
```

```
## Situação vs Crédito: 8.230077e-50
```

```
cat("Produtos vs Crédito: ", qui_3$p.value, "\n")
```

```
## Produtos vs Crédito: 7.634666e-14
```

os testes provam que as três variáveis são fortemente dependentes entre si.


o comportamento dos clientes da Nissa Bank não é aleatório. A situação profissional de um cliente está diretamente amarrada ao tipo de produto que ele consome e ao tipo de crédito que ele pega. Da mesma forma, o produto que ele tem dita o tipo de crédito que ele utiliza.

esses resultados dão a validação científica perfeita para a escolha das suas features. Se um p-value desses tivesse dado maior que 0,05, significaria que a variável era “ruído” (irrelevante) e criar dummies para ela só serviria para deixar o algoritmo *K*-means confuso e lento. Como todas mostraram associações gigantescas, você acabou de provar que deixar as três variáveis na base e transformá-las em dummies é o caminho correto, pois cada uma delas carrega um padrão de comportamento único e crucial para desenhar os 4 perfis de clientes da agência.

segmentação de clientes


escolha da quantidade de grupos

```
# gráfico do cotovelo
fviz_nbclust(pronto_tudo, kmeans, method = "wss", linecolor = "#FF10F0") +
  labs(title = "Teste do Cotovelo (Método WSS)", x = "Número de Clusters K", y = "Soma os Quadrados Den
```



```
# gráfico da silhueta média
fviz_nbclust(pronto_tudo, kmeans, method = "silhouette", linecolor = "#FF10F0") +
  labs(title = "Teste do Coeficiente de Silhueta", x = "Número de Clusters K", y = "Silhueta Média")
```


Teste do Coeficiente de Silhueta



quando não sabemos a quantidade ideal de grupos para dividir nossos clientes, fazemos uma análise de clustering exploratória primeiro, e nesse caso a análise é feita com o *agrupamento hierárquico*, que é uma técnica não supervisionada de machine learning, ou seja, ela não serve para extrapolar a amostra, mas serve muito bem para o que preciso agora que é ter uma ideia de como os clusters se dividem naturalmente.

ele cria um gráfico chamado “dendograma” que mostra como os clusters se dividem.

```
# 1. calcula a matriz de distância geométrica
matriz_distancia <- dist(pronto_tudo, method = "euclidean")


# 2. executa o agrupamento hierárquico (Método de Ward)
modelo_hierarquico <- hclust(matriz_distancia, method = "ward.D2")

# 3. converte o resultado para um objeto dendrograma
dend <- as.dendrogram(modelo_hierarquico)

# 4. colore as ramificações dos 4 grupos com as cores neon (processamento otimizado)
dend <- color_branches(dend, k = 4, col = c("#39FF14", "#FF10F0", "#FF5F1F", "#00FFFF"))

# 5. plota o dendrograma modificado removendo os rótulos individuais das folhas (leaflab = "none")
plot(dend, leaflab = "none", main = "Dendrograma de Clientes - Análise Exploratória",
     xlab = "Clientes", ylab = "Distância")
```

Dendrograma de Clientes – Análise Exploratória



e quando nós já fizemos uma análise prévia e já decidimos quantos grupos vamos trabalhar, passamos para outra técnica de machine learning não supervisionado, o *K-means*.

k-means be like:



só que, nesse caso, precisamos escolher entre o que os dados estão nos indicando e o que é prático no mundo

real.

```
# ANÁLISE DOS DOIS MODELOS EM PARALELO (4 E 8 CLUSTERS)

# garante que os resultados sejam sempre os mesmos ao rodar
set.seed(123)

# modelo A: a preferência do negócio (4 Clusters)
modelo_k4 <- kmeans(pronto_tudo, centers = 4, nstart = 25)
dados_modif$cluster_4 <- as.factor(modelo_k4$cluster)

# modelo B: o ideal matemático (8 Clusters)
modelo_k8 <- kmeans(pronto_tudo, centers = 8, nstart = 25)
dados_modif$cluster_8 <- as.factor(modelo_k8$cluster)

# COMPARAÇÃO DO TAMANHO DOS GRUPOS
cat("=== DISTRIBUIÇÃO DOS CLIENTES EM 4 CLUSTERS ===\n")
```

```
## === DISTRIBUIÇÃO DOS CLIENTES EM 4 CLUSTERS ===
```

```
print(table(dados_modif$cluster_4))
```

```
##
##      1      2      3      4
## 1196 1391 1402 1023
```

```
cat("\n")
```

```
cat("=== DISTRIBUIÇÃO DOS CLIENTES EM 8 CLUSTERS ===\n")
```

```
## === DISTRIBUIÇÃO DOS CLIENTES EM 8 CLUSTERS ===
```

```
print(table(dados_modif$cluster_8))
```

```
##
##      1      2      3      4      5      6      7      8
##  722  622  616  526  468  872  489  697
```



```
cat("\n#####\n")
```

```
##
## #####
```

```
cat("          CARACTERÍSTICAS DOS 4 CLUSTERS          \n")
```

```
##          CARACTERÍSTICAS DOS 4 CLUSTERS
```

```
cat("#####\n\n")
```

```
## #####
```

```
# 1. numéricas (Mediana) para 4 clusters
```

```
perfil_num_k4 <- aggregate(cbind(age, revenu_mensuel, epargne) ~ cluster_4, data = dados_modif, FUN = m
perfil_num_k4[, 2:4] <- round(perfil_num_k4[, 2:4], 2)
print("=== NUMÉRICAS (Mediana) ===")
```

```
## [1] "=== NUMÉRICAS (Mediana) ==="
```

```
print(perfil_num_k4)
```

```
## cluster_4 age revenu_mensuel epargne
## 1         1  41         1884.72 1680.95
## 2         2  33          975.68  382.61
## 3         3  44         1595.93  972.40
## 4         4  38         1152.70  523.88
```

```
# 2. categóricas (Proporção) para 4 clusters
```

```
cat("\n=== CATEGÓRICAS: Situação Profissional (%) ===\n")
```

```
##
```

```
## === CATEGÓRICAS: Situação Profissional (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_4, dados_modif$situation), margin = 1), 4) * 100)
```

```
##
```

```
## Agent d'entretien Aide à domicile Artisan Caissier Employé Employé précaire
```

```
## 1 0.00 0.00 0.00 0.00 100.00 0.00
```

```
## 2 1.44 2.95 5.97 2.37 0.00 14.74
```

```
## 3 3.42 6.85 12.77 6.70 0.00 27.10
```

```
## 4 1.96 4.30 8.21 2.74 0.00 23.17
```

```
##
```

```
## Entrepreneur local Étudiant Fonctionnaire Livreur Retraité Sans emploi
```

```
## 1 0.00 0.00 0.00 0.00 0.00 0.00
```

```
## 2 2.59 30.98 4.39 1.80 5.97 25.09
```

```
## 3 8.27 0.00 15.05 3.28 12.34 0.00
```

```
## 4 3.13 18.67 6.06 2.54 9.87 17.30
```

```
##
```

```
## Serveur
```

```
## 1 0.00
```

```
## 2 1.73
```

```
## 3 4.21
```

```
## 4 2.05
```

```
cat("\n=== CATEGÓRICAS: Produtos Detidos (%) ===\n")
```

```
##
```

```
## === CATEGÓRICAS: Produtos Detidos (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_4, dados_modif$produits_detenus), margin = 1), 4) * 100)
```

```
##
```

```
## Compte courant Compte courant + Assurance habitation
```

```
## 1 20.32 22.24
```

```
## 2 27.46 0.00
```

```
## 3 43.51 28.39
```

```
## 4 0.00 0.00
```

```
##
```

```
## Compte courant + Carte bancaire Compte courant + Carte bancaire + Livret A
```

```
## 1 21.07 17.73
```

```
## 2 72.54 0.00
```

```
## 3 0.00 28.10
```

```
## 4 0.00 0.00
```

```
##
```

```
## Compte courant + Livret A
```

```
## 1 18.65
```

```
## 2 0.00
```

```
## 3 0.00
```

```
## 4 100.00
```

```

cat("\n=== CATEGÓRICAS: Crédito em Curso (%) ===\n")

##
## === CATEGÓRICAS: Crédito em Curso (%) ===

print(round(prop.table(table(dados_modif$cluster_4, dados_modif$credit_en_cours), margin = 1), 4) * 100)

##
##      Aucun crédit  Crédit consommation  Découvert autorisé  Microcrédit
##  1          20.48              17.39              19.40          21.91
##  2          31.42              20.13              21.50          20.27
##  3          22.61              18.26              19.19          21.26
##  4          29.81              18.48              20.04          22.39
##
##      Prêt automobile
##  1          20.82
##  2           6.69
##  3          18.69
##  4           9.29

cat("\n\n#####\n")

##
##
## #####

cat("                CARACTERÍSTICAS DOS 8 CLUSTERS                \n")

##                CARACTERÍSTICAS DOS 8 CLUSTERS

cat("#####\n\n")

## #####

# 1. numéricas (mediana) para 8 clusters
perfil_num_k8 <- aggregate(cbind(age, revenu_mensuel, epargne) ~ cluster_8, data = dados_modif, FUN = m
perfil_num_k8[, 2:4] <- round(perfil_num_k8[, 2:4], 2)
print("=== NUMÉRICAS (Mediana) ===")

## [1] "=== NUMÉRICAS (Mediana) ==="

print(perfil_num_k8)

##      cluster_8 age revenu_mensuel epargne
##  1           1  41      1866.90 1658.14
##  2           2  22       583.44  384.96
##  3           3  44      1714.72 1216.12
##  4           4  40       571.76  181.16
##  5           5  45      1780.71 1439.23
##  6           6  47      1711.84 1290.70
##  7           7  42      1578.65  971.88
##  8           8  41      1280.82  575.00

```

```
# 2. categóricas (proporção) para 8 clusters
cat("\n=== CATEGÓRICAS: Situação Profissional (%) ===\n")

##
## === CATEGÓRICAS: Situação Profissional (%) ===

print(round(prop.table(table(dados_modif$cluster_8, dados_modif$situation), margin = 1), 4) * 100)
```

```
##
##      Agent d'entretien Aide à domicile Artisan Caissier Employé Employé précaire
##  1          0.00          0.00      0.00      0.00 100.00          0.00
##  2          0.00          0.00      0.00      0.00  0.00          0.00
##  3          3.25          6.66 13.47      5.36 34.09          0.00
##  4          0.00          0.00      0.00      0.00  0.00          0.00
##  5          2.14          5.34 11.11      3.63 44.44          0.00
##  6          5.28          9.40 17.20      8.49  0.00          0.00
##  7          2.45          6.75 12.47      6.34 11.45         25.56
##  8          0.00          0.00      0.00      0.00  0.00        100.00
##
##      Entrepreneur local Étudiant Fonctionnaire Livreur Retraité Sans emploi
##  1          0.00      0.00          0.00      0.00      0.00      0.00
##  2          0.00    100.00          0.00      0.00      0.00      0.00
##  3          5.84      0.00          9.90      4.06 13.47      0.00
##  4          0.00      0.00          0.00      0.00      0.00    100.00
##  5          5.56      0.00         11.32      3.63 10.26      0.00
##  6         10.21      0.00         19.15      4.70 20.07      0.00
##  7          6.75      0.00         10.84      2.86 10.43      0.00
##  8          0.00      0.00          0.00      0.00      0.00      0.00
##
##      Serveur
##  1      0.00
##  2      0.00
##  3      3.90
##  4      0.00
##  5      2.56
##  6      5.50
##  7      4.09
##  8      0.00
```

```
cat("\n=== CATEGÓRICAS: Produtos Detidos (%) ===\n")

##
## === CATEGÓRICAS: Produtos Detidos (%) ===

print(round(prop.table(table(dados_modif$cluster_8, dados_modif$produits_detenus), margin = 1), 4) * 100)

##
##      Compte courant Compte courant + Assurance habitation
##  1          26.87          31.16
##  2          34.08           0.00
##  3           0.00           0.00
```



```
## 4      32.32      0.00
## 5      24.79     21.58
## 6      26.95     23.17
## 7      26.99     17.59
## 8      25.25      7.17
##
##      Compte courant + Carte bancaire  Compte courant + Carte bancaire + Livret A
## 1              0.00              24.10
## 2             35.21              0.00
## 3            100.00              0.00
## 4             34.03              0.00
## 5              8.97             19.66
## 6              0.00             21.22
## 7              0.00             16.36
## 8             29.41             10.76
##
##      Compte courant + Livret A
## 1             17.87
## 2             30.71
## 3              0.00
## 4             33.65
## 5             25.00
## 6             28.67
## 7             39.06
## 8             27.40
```

```
cat("\n=== CATEGÓRICAS: Crédito em Curso (%) ===\n")
```

```
##
## === CATEGÓRICAS: Crédito em Curso (%) ===
```

```
print(round(prop.table(table(dados_modif$cluster_8, dados_modif$credit_en_cours), margin = 1), 4) * 100)
```

```
##
##      Aucun crédit  Crédit consommation  Découvert autorisé  Microcrédit
## 1      27.29      0.00      25.48      20.36
## 2      38.91     19.13     21.22     20.74
## 3      23.21     12.34     20.45     23.38
## 4      34.79     21.10     21.86     22.24
## 5       0.00    100.00      0.00      0.00
## 6      36.70      0.00     32.00      0.00
## 7       0.00      0.00      0.00    100.00
## 8      31.42     22.81     24.25      6.46
##
##      Prêt automobile
## 1      26.87
## 2       0.00
## 3     20.62
## 4       0.00
## 5       0.00
## 6     31.31
## 7       0.00
## 8     15.06
```

o escolhido foi o modelo de 4 grupos, porque é impraticável uma empresa ter mais de 4 personas para se comunicar. o trabalho de marketing tem que ser muito bem definido e coeso, o que não seria possível com 8 grupos, até porque quem fala com todo mundo, não fala com ninguém ;)

```
# RESUMO INDIVIDUALIZADO POR PERSONA (K = 4)

for (i in 1:4) {
  cat("\n===== \n")
  cat(paste("                PERFIL DA PERSONA", i, "\n"))
  cat("===== \n")

  # isola os dados apenas do cluster iterado no momento
  dados_cluster <- subset(dados_modif, cluster_4 == i)

  # calcula o tamanho do grupo em relação ao total de clientes da agência
  tamanho <- nrow(dados_cluster)
  proporcao_base <- round((tamanho / nrow(dados_modif)) * 100, 2)
  cat(paste("Volume de Clientes: ", tamanho, " (", proporcao_base, "% da base total)\n\n", sep = ""))

  # indicadores numéricos (mediana)
  cat("--- Indicadores Numéricos ---\n")
  cat("• Idade:           ", median(dados_cluster$age), "anos\n")
  cat("• Renda Mensal:     €", round(median(dados_cluster$revenu_mensuel), 2), "\n")
  cat("• Poupança:         €", round(median(dados_cluster$epargne), 2), "\n\n")

  # indicadores Categóricos (Exibe apenas as categorias presentes no grupo > 0%)
  cat("--- Comportamento Categórico Interno ---\n")

  cat("\n> Situação Profissional (%):\n")
  freq_sit <- round(prop.table(table(dados_cluster$situation)) * 100, 2)
  print(freq_sit[freq_sit > 0])

  cat("\n> Produtos Detidos (%):\n")
  freq_prod <- round(prop.table(table(dados_cluster$produits_detenus)) * 100, 2)
  print(freq_prod[freq_prod > 0])

  cat("\n> Crédito em Curso (%):\n")
  freq_cred <- round(prop.table(table(dados_cluster$credit_en_cours)) * 100, 2)
  print(freq_cred[freq_cred > 0])
}
```

```
##
## =====
##                PERFIL DA PERSONA 1
## =====
## Volume de Clientes: 1196 (23.86% da base total)
##
## --- Indicadores Numéricos ---
## • Idade:           41 anos
## • Renda Mensal:     € 1884.72
## • Poupança:         € 1680.95
##
## --- Comportamento Categórico Interno ---
##
```

```

## > Situação Profissional (%):
## Employé
##      100
##
## > Produtos Detidos (%):
##
##              Compte courant
##              20.32
##      Compte courant + Assurance habitation
##              22.24
##      Compte courant + Carte bancaire
##              21.07
##      Compte courant + Carte bancaire + Livret A
##              17.73
##      Compte courant + Livret A
##              18.65
##
## > Crédito em Curso (%):
##
##      Aucun crédit  Crédit consommation  Découvert autorisé  Microcrédit
##      20.48          17.39          19.40          21.91
##      Prêt automobile
##      20.82
##
## =====
##                      PERFIL DA PERSONA 2
## =====
## Volume de Clientes: 1391 (27.75% da base total)
##
## --- Indicadores Numéricos ---
## • Idade:          33 anos
## • Renda Mensal:   € 975.68
## • Poupança:       € 382.61
##
## --- Comportamento Categórico Interno ---
##
## > Situação Profissional (%):
##
##      Agent d'entretien  Aide à domicile  Artisan  Caissier
##      1.44              2.95              5.97    2.37
##      Employé précaire  Entrepreneur local  Étudiant  Fonctionnaire
##      14.74             2.59             30.98    4.39
##      Livreur           Retraité           Sans emploi  Serveur
##      1.80              5.97             25.09    1.73
##
## > Produtos Detidos (%):
##
##      Compte courant  Compte courant + Carte bancaire
##      27.46          72.54
##
## > Crédito em Curso (%):
##
##      Aucun crédit  Crédit consommation  Découvert autorisé  Microcrédit
##      31.42          20.13          21.50          20.27

```

```

##      Prêt automobile
##          6.69
##
## =====
##                      PERFIL DA PERSONA 3
## =====
## Volume de Clientes: 1402 (27.97% da base total)
##
## --- Indicadores Numéricos ---
## • Idade:          44 anos
## • Renda Mensal:   € 1595.93
## • Poupança:       € 972.4
##
## --- Comportamento Categórico Interno ---
##
## > Situação Profissional (%):
##
## Agent d'entretien   Aide à domicile          Artisan          Caissier
##          3.42          6.85          12.77          6.70
## Employé précaire Entrepreneur local      Fonctionnaire      Livreur
##          27.10          8.27          15.05          3.28
##          Retraité          Serveur
##          12.34          4.21
##
## > Produtos Detidos (%):
##
##                      Compte courant
##                      43.51
##      Compte courant + Assurance habitation
##                      28.39
## Compte courant + Carte bancaire + Livret A
##                      28.10
##
## > Crédito em Curso (%):
##
##      Aucun crédit Crédit consommation Découvert autorisé      Microcrédit
##          22.61          18.26          19.19          21.26
##      Prêt automobile
##          18.69
##
## =====
##                      PERFIL DA PERSONA 4
## =====
## Volume de Clientes: 1023 (20.41% da base total)
##
## --- Indicadores Numéricos ---
## • Idade:          38 anos
## • Renda Mensal:   € 1152.7
## • Poupança:       € 523.88
##
## --- Comportamento Categórico Interno ---
##
## > Situação Profissional (%):
##

```

```
## Agent d'entretien Aide à domicile Artisan Caissier
## 1.96 4.30 8.21 2.74
## Employé précaire Entrepreneur local Étudiant Fonctionnaire
## 23.17 3.13 18.67 6.06
## Livreur Retraité Sans emploi Serveur
## 2.54 9.87 17.30 2.05
##
## > Produtos Detidos (%):
## Compte courant + Livret A
## 100
##
## > Crédito em Curso (%):
##
## Aucun crédit Crédit consommation Découvert autorisé Microcrédit
## 29.81 18.48 20.04 22.39
## Prêt automobile
## 9.29
```

sugestões de produtos bancários para cada grupo

```
# ANÁLISE DE AFINIDADE (LIFT) PARA CROSS-SELLING E UP-SELLING
```

```
cat("\n#####\n")
```

```
##
## #####
```

```
cat(" CÁLCULO DE LIFT (AFINIDADE) POR CLUSTER \n")
```

```
## CÁLCULO DE LIFT (AFINIDADE) POR CLUSTER
```

```
cat("#####\n")
```

```
## #####
```

```
# 1. calcula a proporção de cada produto e crédito na base TOTAL da agência
```

```
prop_base_produtos <- prop.table(table(dados_modif$produits_detenus))
```

```
prop_base_credito <- prop.table(table(dados_modif$credit_en_cours))
```

```
# 2. loop para calcular e imprimir o Lift para cada um dos 4 clusters
```

```
for (i in 1:4) {
```

```
  cat("\n===== \n")
```

```
  cat(paste(" LIFT - CLUSTER", i, "\n"))
```

```
  cat("===== \n")
```

```
  # filtra os dados apenas para o cluster atual
```

```
  dados_cluster <- subset(dados_modif, cluster_4 == i)
```

```
  # calcula a proporção de produtos e créditos dentro do cluster
```

```
  prop_cluster_produtos <- prop.table(table(dados_cluster$produits_detenus))
```

```

prop_cluster_credito <- prop.table(table(dados_cluster$credit_en_cours))

# calcula o Lift (Proporção no Cluster dividida pela Proporção na Base Geral)
lift_produtos <- prop_cluster_produtos / prop_base_produtos
lift_credito <- prop_cluster_credito / prop_base_credito

# exibe os resultados separados entre o que deve ser ofertado e o que deve ser evitado
cat("\n> PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):\n")
produtos_fortes <- round(lift_produtos[lift_produtos > 1], 2)
if(length(produtos_fortes) > 0) print(sort(produtos_fortes, decreasing = TRUE)) else cat("Nenhum produto forte.\n")

cat("\n> PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):\n")
produtos_fracos <- round(lift_produtos[lift_produtos < 1], 2)
if(length(produtos_fracos) > 0) print(sort(produtos_fracos)) else cat("Nenhum produto fraco.\n")

cat("\n-----\n")

cat("> CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):\n")
creditos_fortes <- round(lift_credito[lift_credito > 1], 2)
if(length(creditos_fortes) > 0) print(sort(creditos_fortes, decreasing = TRUE)) else cat("Nenhum crédito forte.\n")

cat("\n> CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):\n")
creditos_fracos <- round(lift_credito[lift_credito < 1], 2)
if(length(creditos_fracos) > 0) print(sort(creditos_fracos)) else cat("Nenhum crédito fraco.\n")
}

```

```

##
## =====
##                               LIFT - CLUSTER 1
## =====
##
## > PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
##      Compte courant + Assurance habitation
##                               1.68
## Compte courant + Carte bancaire + Livret A
##                               1.47
##
## > PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##      Compte courant + Livret A          Compte courant
##                               0.75                0.82
## Compte courant + Carte bancaire
##                               0.84
##
## -----
## > CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
## Prêt automobile      Microcrédit
##      1.49            1.03
##
## > CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##

```

```

##          Aucun crédit Crédit consommation Découvert autorisé
##              0.79              0.93              0.97
##
## =====
##              LIFT - CLUSTER 2
## =====
##
## > PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
## Compte courant + Carte bancaire          Compte courant
##              2.88              1.11
##
## > PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##      Compte courant + Assurance habitation
##              0
## Compte courant + Carte bancaire + Livret A
##              0
##      Compte courant + Livret A
##              0
##
## -----
## > CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
##          Aucun crédit Crédit consommation Découvert autorisé
##              1.21              1.08              1.07
##
## > CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
## Prêt automobile      Microcrédit
##              0.48              0.95
##
## =====
##              LIFT - CLUSTER 3
## =====
##
## > PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
## Compte courant + Carte bancaire + Livret A
##              2.32
##      Compte courant + Assurance habitation
##              2.14
##              Compte courant
##              1.77
##
## > PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
## Compte courant + Carte bancaire          Compte courant + Livret A
##              0              0
##
## -----
## > CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
## Prêt automobile
##              1.34

```

```

##
## > CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##      Aucun crédit   Découvert autorisé   Crédit consommation   Microcrédit
##              0.87                0.96                0.98                0.99
##
## =====
##                      LIFT - CLUSTER 4
## =====
##
## > PRODUTOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
## Compte courant + Livret A
##              4.02
##
## > PRODUTOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##                      Compte courant
##                      0
##      Compte courant + Assurance habitation
##                      0
##      Compte courant + Carte bancaire
##                      0
## Compte courant + Carte bancaire + Livret A
##                      0
##
## -----
## > CRÉDITOS PARA CROSS-SELLING (Alta Afinidade | Lift > 1):
##
## Aucun crédit   Microcrédit
##      1.15        1.05
##
## > CRÉDITOS PARA EVITAR (Baixa Afinidade | Lift < 1):
##
##      Prêt automobile   Crédit consommation   Découvert autorisé
##              0.67                0.99                1.00

```

por que precisamos de um bom sistema de gestão de dados comerciais?

1. segmentação precisa e aumento de vendas (cross-selling): um sistema de gestão de dados estruturado e limpo é o pré-requisito fundamental para aplicar algoritmos de inteligência artificial, como a clusterização K-means que você acabou de executar. Ele permite cruzar histórico de transações com dados demográficos para calcular a afinidade de produtos (Lift). Sem esse sistema, o banco faria ofertas genéricas; com ele, a agência consegue direcionar a campanha de microcrédito exatamente para a persona com maior probabilidade de conversão.
2. eficiência operacional e mitigação de riscos de crédito: a integração de dados comerciais elimina silos de informação dentro da agência. Quando o gerente acessa o perfil de um cliente, ele vê o quadro completo em tempo real (idade, renda, poupança e créditos ativos). Isso não apenas acelera o tempo de atendimento presencial, mas fornece uma base matemática segura para a análise de risco, evitando a concessão de limite de cheque especial ou novos empréstimos para perfis com alta probabilidade de inadimplência.

3. conformidade regulatória e segurança da informação (RGPD): operando na França, a gestão rigorosa de dados de clientes é uma exigência legal imposta pelo Regulamento Geral sobre a Proteção de Dados (RGPD). Um sistema comercial sólido garante que informações financeiras sensíveis sejam armazenadas com criptografia adequada e controle de acesso. Além disso, permite gerenciar o consentimento dos clientes e executar rapidamente solicitações de direito ao esquecimento ou portabilidade de dados, blindando a agência contra vazamentos e multas severas.
-

KPIs para acompanhar na agência do Nissa Bank

4. Definição de KPI para pilotar a agência

Para gerenciar de forma estratégica as ações de marketing e o desempenho comercial da agência Nissa Bank, propõem-se 5 Indicadores-Chave de Desempenho (KPIs) mensuráveis e focados em relacionamento, conversão e retenção:

1. Taxa de Evolução de Venda Cruzada (Taux d'Évolution de Cross-Selling)

- **O que mede:** O percentual de clientes que possuíam apenas o produto básico (Conta Corrente) e que adquiriram pelo menos um produto adicional (seguro, poupança ou crédito) após as ações de marketing.
- **Fórmula de cálculo:**

$$\left(\frac{\text{Número de clientes que adquiriram novos produtos no período}}{\text{Total de clientes que possuíam apenas Conta Corrente no início do período}} \right) \times 100$$

- **Justificativa de negócios:** Este indicador mede o movimento real de conversão. Ele prova a eficácia do time de marketing em transformar um cliente “monoproduto” em um cliente multi-equipado usando a estratégia de Lift.

2. Taxa de Rotatividade de Clientes (Taux d'Attrition / Churn Rate)

- **O que mede:** O percentual de clientes que encerraram suas contas ou ficaram totalmente inativos em um determinado período.
- **Fórmula de cálculo:**

$$\left(\frac{\text{Número de clientes perdidos no trimestre}}{\text{Número total de clientes ativos no início do trimestre}} \right) \times 100$$

- **Justificativa de negócios:** KPI vital de retenção. No varejo bancário, manter um cliente ativo custa menos do que adquirir um novo. Uma alta taxa de atrito em um cluster específico indica insatisfação com tarifas ou falta de produtos adequados para aquele perfil.

3. Taxa de Penetração de Produtos de Proteção por Segmento (Taux de Pénétration des Assurances)

- **O que mede:** O percentual de clientes de um determinado cluster que adotou produtos de proteção (seguros) recomendados pela análise de afinidade.
- **Fórmula de cálculo:**

$$\left(\frac{\text{Número de clientes do Cluster X com pelo menos um Seguro ativo}}{\text{Total de clientes mapeados no Cluster X}} \right) \times 100$$

- **Justificativa de negócios:** Permite monitorar a aderência das personas a categorias de produtos de maior margem para o banco (como *Assurance Habitation* ou *Assurance Santé*). Se o Cluster 2 tem alto Lift para seguros, essa taxa deve ser acompanhada mensalmente para medir o Market Share interno daquele grupo.

4. Taxa de Reativação de Clientes Inativos (Taux de Réactivation)

- **O que mede:** O percentual de clientes sem movimentação financeira ou sem produtos ativos que voltaram a transacionar após estímulos de campanhas de marketing.
- **Fórmula de cálculo:**

$$\left(\frac{\text{Clientes inativos que realizaram uma nova contratação ou transação no mês}}{\text{Total de clientes classificados como inativos no início do mês}} \right) \times 100$$

- **Justificativa de negócios:** Muito aplicável ao contexto de QPV, onde clientes de clusters de menor renda (como desempregados ou estudantes) podem deixar a conta inativa temporariamente. O marketing utiliza esse KPI para avaliar a eficácia de campanhas de incentivo e microcréditos de reentrada.

5. Taxa de Bancarização Digital por Segmento (Taux d'Activation de l'Application Mobile)

- **O que mede:** O percentual de clientes ativos da agência que possuem o aplicativo móvel do banco instalado e com o primeiro acesso realizado.
- **Fórmula de cálculo:**

$$\left(\frac{\text{Número de clientes do cluster com pelo menos 1 acesso ao App nos últimos 90 dias}}{\text{Total de clientes mapeados no mesmo cluster}} \right) \times 100$$

- **Justificativa de negócios:** Avalia o sucesso das campanhas de inclusão digital. Diante do cenário francês, onde mais de 1 em cada 3 pessoas enfrenta barreiras de exclusão digital (*illectronisme*), e o risco de analfabetismo funcional digital é 2,4 vezes maior dentro de territórios vulneráveis (QPV), monitorar essa taxa é essencial. Ela permite ao marketing identificar quais perfis precisam de suporte presencial e pedagógico na agência em vez de apenas comunicações digitais.

-
5. Ações diárias do encarregado de dados (Data Analyst) Para fazer a segmentação rodar na prática e garantir a eficácia das campanhas de cross-selling da agência Nissa Bank, o encarregado de dados deve realizar as seguintes tarefas diárias:

Acompanhamento e integração de novos clientes (Atualização do modelo): Automatizar um script que processe os novos perfis criados na jornada diária, aplique a transformação de padronização Min-Max e os classifique instantaneamente em um dos 4 clusters definidos, garantindo que recebam comunicações e ofertas personalizadas desde o primeiro contato.

Extração de listas-alvo para os gerentes (Campanhas de Cross-selling): Extrair diariamente listas de clientes específicas baseadas nos resultados do cálculo de Lift (por exemplo, exportar a lista de todos os clientes do cluster de aposentados que possuem alta afinidade com seguros, mas que ainda não contrataram um seguro saúde) para alimentar o CRM dos gerentes comerciais.

Controle de qualidade e limpeza de dados (Data Quality): Monitorar rotinas automatizadas para identificar anomalias e erros de digitação manual por parte dos gerentes (como rendas preenchidas incorretamente ou profissões desatualizadas) e solicitar a correção imediata, evitando a corrupção dos modelos de Machine Learning.

Monitoramento de KPIs e controle de riscos: Atualizar diariamente os painéis de desempenho da agência, acompanhando de perto a taxa de conversão das campanhas por cluster e o índice de inadimplência nos microcréditos, de modo a alertar a diretoria em caso de desvios operacionais ou aumento do risco de crédito.

6. Exemplos da utilidade de uma base de dados bem preenchida Uma base de dados rigorosamente qualificada, higienizada e atualizada transforma a gestão estratégica e operacional do Nissa Bank, permitindo que a instituição financeira saia de uma postura puramente reativa e adote uma abordagem preditiva e prescritiva:

Exemplo 1: Antecipação de riscos e suporte preventivo em cenários de vulnerabilidade socioeconômica (QPV): Em uma região classificada como QPV, as mudanças na renda dos clientes podem ser repentinas e severas, decorrentes de desemprego ou término de auxílios governamentais. Se a base de dados mantiver o histórico preciso dos fluxos financeiros e depósitos, o analista pode programar alertas automáticos para quando os recebimentos de um cliente caírem abaixo de um limite crítico. Isso permite que a agência aja preventivamente, agendando um atendimento de orientação orçamentária ou oferecendo uma reestruturação de dívidas antes que o cliente entre no cheque especial ou fique inadimplente, mitigando o risco de crédito da agência e apoiando a saúde financeira da comunidade local.

Exemplo 2: Otimização do Retorno sobre Investimento (ROI) de Marketing e eliminação do “spam” bancário: Em vez de desperdiciar recursos financeiros e operacionais enviando malas diretas ou panfletos de crédito imobiliário para todos os 5.012 clientes da agência de forma indiscriminada — o que gera custos desnecessários, baixa taxa de conversão e satura o público —, uma base de dados bem preenchida permite aplicar filtros granulares. O sistema isola apenas as pessoas pertencentes ao cluster de funcionários públicos com renda estável e que não possuem nenhum financiamento ativo na casa. O impacto comercial é maximizado porque a oferta se alinha perfeitamente ao momento de vida, à necessidade latente e à capacidade financeira real do público-alvo escolhido.

Exemplo 3: Automação de gatilhos comerciais e retenção de clientes no ciclo de transição civil: A integração correta de dados demográficos essenciais, como a data de nascimento associada ao portfólio de produtos ativos, permite disparar réguas de relacionamento automatizadas de forma cirúrgica. No dia em que um cliente pertencente ao cluster de estudantes completa 26 anos de idade, o sistema operacional da base de dados pode disparar um gatilho automático para atualizar a sua conta para uma modalidade padrão, desativar os benefícios do “Cartão Jovem” e enviar um convite personalizado para uma primeira conversa sobre investimentos ou planos de previdência. Isso garante a transição comercial e a retenção do cliente de forma fluida, sem demandar análise ou esforço manual da equipe de atendimento.

Um argumento escrito (1 página): Por que um bom sistema de gestão de dados é essencial, em particular para uma agência em QPV Introdução A análise avançada de dados dentro da agência Nissa Bank, localizada no coração de um Bairro Prioritário da Cidade (QPV) em Nice, demonstra que um sistema de gestão de dados comerciais estruturado não constitui um mero capricho técnico ou um repositório burocrático. Ele se estabelece como o pilar central indispensável para a viabilidade econômica da agência e para a promoção de uma inclusão financeira responsável. Em territórios caracterizados por dinâmicas socioeconômicas complexas e vulnerabilidades estruturais, a operação bancária tradicional baseada em intuição ou ofertas massificadas está fadada à ineficiência e ao aumento do risco operacional. Três argumentos científicos e comerciais fundamentam de forma sólida a necessidade de investimentos contínuos em uma infraestrutura de dados robusta e qualificada para este cenário.

Argumento 1: Maximização da performance comercial e eficiência na alocação de recursos através do Cross-selling direcionado Em um mercado financeiro altamente competitivo, e especialmente em uma localidade de baixa renda média como um QPV, as abordagens de marketing generalistas geram desperdício de capital e ruído na comunicação. Um sistema de gestão de dados íntegro e limpo é o pré-requisito técnico absoluto para a aplicação de algoritmos de aprendizado de máquina não supervisionado, como a clusterização K-means e o posterior cálculo estatístico do Índice de Afinidade (Lift). A ciência de dados transforma dados brutos em inteligência comercial ao apontar quais perfis específicos possuem propensão matemática a adquirir determinados produtos, como microcréditos para microempreendedores locais ou planos de poupança básica (Livret A) para perfis conservadores. Ao cruzar essas métricas, o departamento de marketing consegue direcionar as campanhas de vendas de forma cirúrgica, abordando exclusivamente os clientes que demonstram uma necessidade latente pelo produto. Essa precisão eleva significativamente as taxas de conversão de vendas cruzadas (cross-selling) e de elevação de categoria (up-selling), garantindo a rentabilidade da agência sem saturar ou pressionar financeiramente o público consumidor.

Argumento 2: Mitigação proativa do risco de crédito e otimização da eficiência operacional da agência O gerenciamento de uma instituição financeira em um território economicamente sensível exige uma vigilância rigorosa sobre a concessão de crédito, o uso do limite de cheque especial e a saúde da carteira de ativos. A centralização de dados em um sistema comercial moderno elimina os chamados silos de informação — quando os dados de contas, empréstimos e seguros ficam isolados em setores diferentes e não se comunicam. Com a integração em tempo real, no momento em que um gerente de contas inicia o atendimento a um cliente, o sistema fornece uma visão holística instantânea de suas variáveis críticas (idade, profissão exata, renda líquida mensal, poupança acumulada e nível de endividamento corrente). Essa transparência analítica mune o gestor com bases matemáticas sólidas para avaliar o risco de inadimplência de forma ágil, permitindo ajustar limites de cheque especial preventivamente, evitar situações de superendividamento familiar e conceder microcréditos produtivos a artesãos e pequenos comerciantes de forma segura, blindando o patrimônio da agência contra perdas operacionais.

Argumento 3: Garantia de conformidade regulatória (RGPD) e proteção ética de populações vulneráveis Atuar no cenário bancário francês e europeu implica estar sob a estrita e rigorosa vigilância do Regulamento Geral sobre a Proteção de Dados (RGPD), além das normas de supervisão da ACPR e do Banque de France. Um sistema de gestão comercial maduro oferece os mecanismos de segurança necessários para garantir o tratamento lícito de dados financeiros e pessoais altamente sensíveis. Isso engloba a criptografia de ponta a ponta dos registros, a auditoria e rastreabilidade de acessos por parte dos funcionários e o gerenciamento automatizado dos termos de consentimento de marketing. Para além da blindagem jurídica obrigatória contra vazamentos e multas severas que podem comprometer a continuidade do negócio, a governança rigorosa dos dados desempenha um papel ético fundamental na proteção de clientes de baixa renda ou com menor familiaridade com processos digitais. Um sistema transparente constrói uma relação de confiança mútua entre a comunidade e a instituição de crédito, posicionando o Nissa Bank como um agente de desenvolvimento socioeconômico seguro e legítimo na região.