

TP 2 : FLUCTUATION DES ESTIMATIONS

Exercice 1 : tirage d'échantillons (1) et 2) : D'après un cours et un TP de Christophe Chesneau)

Par exemple, pour faire un tirage sans remise de $n = 20$ individus dans une population de $N = 200$ individus, on peut utiliser

o la commande `sample` :

```
sample(1:200, 20, replace = F)
```

1) a) Rappel : de quel type est la variable 1:200 ?

b) Stocker l'échantillon tiré précédemment dans la variable ech1.

c) A l'aide d'une fonction de R, vérifier qu'il n'y a pas de répétition dans l'échantillon.

Chaque individu de 1:200 a la même probabilité d'être choisi : on parle de **Sondage Aléatoire Simple (SAS)**

2) Autre exemple :

On considère la population P constituée de N=9 garçons et on prélève un échantillon de n=3 individus en effectuant un Sondage Aléatoire Simple :

```
P <- c("Bob", "Nico", "Ali", "Fabien", "Malik", "John", "Jean", "Chris", "Karl")
```

Ecrire le code qui permet d'extraire un échantillon de 3 individus et stocker le résultat dans la variable ech2.

3) a) Stocker dans la variable STID le data frame correspondant aux données du fichier reponsesSTID.csv que vous trouverez dans le dossier TP2 sur Moodle.

Pour des rappels sur l'importation, voir le chapitre sur la manipulation de données de la page web suivante :

<http://beginr.u-bordeaux.fr/>

b) Extraire de cette population, sous forme d'un data frame, un échantillon de 10 individus par SAS.

Exercice 2 : Sondage Aléatoire Simple

1) Installer le package questionr.

2) Charger le jeu de données hdv2003 issu de l'enquête Histoire De Vie de réalisée en 2003 par l'INSEE en tapant :

```
library(questionr)  
data(hdv2003)
```

Les individus de ce jeu de données constitueront notre population.

3) a) Donner la distribution (tri à plat) de la variable nombre de frères et soeurs, en tracer deux représentations graphiques puis commenter.

b) Extraire de cette population, sous forme d'un data frame, un échantillon de 50 individus par SAS et le stocker dans la variable ech.

c) Donner, à partir de cet échantillon, une estimation du nombre moyen de frères et soeurs dans la population.

d) Réitérer l'échantillonnage puis l'estimation 3 fois, commenter les résultats et comparer à la vraie valeur sur la population.

e) Comparer la vraie valeur à vos 4 estimations puis conclure.

4)a) Ecrire une fonction *sondage* qui prend comme argument un data frame *df*, le nom *var* d'une de ses variables quantitatives (sous forme de chaîne de caractère), une taille d'échantillon *n* et qui **retourne** en sortie l'estimations de la moyenne de la population réalisée à partir du tirage par SAS de *n* individus dans le data frame *df* c'est-à-dire qui reproduit le résultat des questions 3) b) et c).

Rappels sur la syntaxe de R : voir Structures algorithmiques et fonctions sur la page <http://beginr.u-bordeaux.fr/>

b) Ecrire une fonction *estimations* qui prend comme argument un data frame *df*, le nom *var* d'une de ses variables quantitatives (sous forme de chaîne de caractère), une taille d'échantillon *n*, le nombre de Sondages Aléatoires Simples *nbSond* à réitérer et qui retourne en sortie le vecteur des *nbSond* estimations de la moyenne de la population réalisées à partir de tirages par SAS d'échantillons de *n* individus dans le data frame *df*.

c) Stocker dans la variable *resultats* le vecteur retourné par *estimations(hdv2003,50, "freres.soeurs", 1000)*

d) Représenter les estimations obtenues par un diagramme en boîte puis observer la symétrie et les valeurs extrêmes. Confirmer en calculant le coefficient d'asymétrie (*skewness()* du package *moments*).

Calculer également le kurtosis puis commenter ces résultats.

Rappels sur la syntaxe de R : voir Statistiques descriptives univariées sur <http://beginr.u-bordeaux.fr/>

e) Représenter les estimations par un histogramme.

Rappels sur la syntaxe de R : http://beginr.u-bordeaux.fr/caps_6_1_loi_normale.html

f) Représenter le diagramme quantile par quantile des estimations et la droite de Henry (*qqline()*) puis conclure.

Rappels sur la syntaxe de R : http://beginr.u-bordeaux.fr/caps_6_3_normalite_graphique_quantile_quantile.html

g) Rajouter le tracé des graphiques des questions d), e) et f) dans votre fonction *estimations*.

5)a) On considère la variable *trav.satisf* et on veut estimer le pourcentage d'individus satisfaits par leur travail dans la population.

Rappeler en quoi cela revient encore à estimer une moyenne.

b) Reprendre les questions du 3) puis du 4) juste pour la variable *trav.satisf* pour estimer le pourcentage d'individus satisfaits par leur travail dans la population.

6) Ecrire une fonction *SAS* qui prend en argument un data frame *df* (base de données de la population), le nom *var* de la variable d'intérêt (chaîne de caractère), la taille *n* de l'échantillon à sonder, le nombre de Sondages Aléatoires Simples *nbSond* à réitérer et qui retourne en sortie le vecteur des *nbSond* estimations de la moyenne de la population réalisées à partir de tirages par SAS d'échantillons de *n* individus dans le data frame *df* ainsi que les autres paramètres et graphes demandés au 4).

On pourra commencer par décomposer le problème en fonctions élémentaires...